

Sprawozdanie 1

Marta Hałas i Igor Misterowicz

2025-11-08

Spis treści

1	Lista 1	2
1.1	Zadanie 1	2
1.1.1	Dystrybuanta	2
1.1.2	Gęstość	2
1.1.3	Funkcja Kwantylowa	2
1.1.4	Funkcja Hazardu	2
1.2	Zadanie 2	3
1.3	Zadanie 3	4
1.4	Zadanie 4	4
1.5	Zadanie 5	5
2	Lista 4	6
2.1	Zadanie 1	6
2.2	Zadanie 2	7
2.3	Zadanie 3	7

1 Lista 1

1.1 Zadanie 1

Poniższe implementacje funkcji związanych z rozkładem wykładniczym-Weilbula $\mathcal{EW}(\alpha, \beta, \gamma)$ przyjmują jako argumenty parametry α, β, γ , a zwracają funkcję jednej zmiennej x .

1.1.1 Dystrybuanta

$$F(x) = [1 - e^{-(x/\beta)^\alpha}]^{1/\gamma}$$

```
pwexp <- function(alpha, beta, gamma){  
  f <- function(x){  
    return ((1 - exp(-(x/beta)^alpha))^gamma)  
  }  
  return(f)  
}
```

1.1.2 Gęstość

$$f(x) = \left(\frac{\gamma\alpha}{\beta}\right) \left(\frac{x}{\beta}\right)^{\alpha-1} [1 - e^{-(x/\beta)^\alpha}]^{\gamma-1} e^{-(x/\beta)^\alpha}$$

```
dwexp <- function(alpha, beta, gamma){  
  f <- function(x){  
    return ((gamma*alpha/beta)*((x/beta)^(alpha - 1))*  
            ((1 - exp(-(x/beta)^(alpha)))^(gamma-1))*exp(-(x/beta)^alpha))  
  }  
  return(f)  
}
```

1.1.3 Funkcja Kwantylowa

$$Q(x) = \beta \left[\ln \left(\frac{1}{1 - x^{1/\gamma}} \right) \right]^{1/\alpha}$$

```
qwexp <- function(alpha, beta, gamma){  
  f <- function(x){  
    return (beta*(-log(1-x^(1/gamma)))^(1/alpha))  
  }  
  return(f)  
}
```

1.1.4 Funkcja Hazardu

$$h(x) = \frac{f(x)}{1 - F(x)}$$

```
hwexp <- function(alpha, beta, gamma){
  den <- dwexp(alpha, beta, gamma)
  dist <- pwexp(alpha, beta, gamma)
  f <- function(x){
    return (den(x)/(1 - dist(x)))
  }
  return(f)
}
```


Tablica 1: Przykładowe wartości funkcji

F(0.5)	Q(0.5)	f(0.5)	h(0.5)
0.795	0.041	0.231	1.129

W Tabeli 1 zostały umieszczone wartości zaimplementowanych funkcji dla $x = \alpha = \beta = \gamma = 0.5$.

1.2 Zadanie 2

Na Wykresie 1 znajdują się funkcje hazardu o różnych, sprecyzowanych na legendzie, parametrach. Użycie aż trzech parametrów zapewnia nam uniwersalność. Dzięki temu możemy opisywać zbiory danych o różnych charakterystykach czasów życia.



Rysunek 1: Wykresy funkcji hazardu

1.3 Zadanie 3

Poniższa funkcja zwraca wektor n realizacji zmiennej losowej o rozkładzie $\mathcal{EW}(\alpha, \beta, \gamma)$. Jej parametry to n, α, β, γ .

```
rwexp <- function(n, alpha, beta, gamma){  
  unifx <- runif(n,0,1)  
  values <- sapply(unifx, FUN = qwexp(alpha, beta, gamma))  
  return(values)  
}
```

Przykład: Wywołanie funkcji **rwexp** dla $n = 5, \alpha = 1, \beta = 2, \gamma = 3$


```
rwexp(5,1,2,3)
```

```
## [1] 2.157986 5.148052 2.711743 6.406891 7.799043
```

1.4 Zadanie 4

Na Wykresie 2, dla danych o rozkładzie wykładniczym-weilbula, znajdziemy porównanie histogramów z teoretycznymi gęstościami. Wybrane parametry oraz liczby obserwacji zostały opisane w legendzie. Jeśli dane interpretować jako czasy życia (w latach), to dla $\alpha = 0.95, \beta = 0.95, \gamma = 0.95$ z upływem czasu obserwujemy malejącą liczbę zgonów, natomiast dla $\alpha = 2, \beta = 2, \gamma = 2$ największa śmiertelność jest w okolicach końca 2 roku.

Dystrybuanty i histogramy rozkładu wykładniczego-Weilbula



Rysunek 2: Dystrybuanty i histogramy Rozkładu Wykładniczego-Weilbula

1.5 Zadanie 5

W Tabeli 2 znajdziemy statystyki opisowe dla danych z zadania 4. “True” w nazwie kolumny oznacza, że wartość została obliczona za pomocą teoretycznej funkcji kwantylowej. Zaskakującą obserwacją dla $\alpha = 0.95, \beta = 0.95, \gamma = 0.95$ jest to, że dla $n = 50$ mamy większy rozstęp niż dla $n = 100$. Zgodnie z intuicją, dla $n = 100$ kwantyle z próby są bliższe kwantylom teoretycznym niż dla $n = 50$.

Tablica 2: Statystyki opisowe dla danych wykładniczych

	Min.	1st Qu.	Med	Mean	3rd Qu.	Max.	Rng	Sd	True Med	True 1.Qu	True 3.Qu
$n = 50, \mathcal{E}\mathcal{W}(0.5, 0.5, 0.5)$	0.01584	0.21	0.56	0.94	1.14	5.29	5.27	1.05	0.61	0.23	1.29
$n = 100, \mathcal{E}\mathcal{W}(0.5, 0.5, 0.5)$	0.00027	0.23	0.56	0.91	1.26	4.24	4.24	0.93	0.61	0.23	1.29
$n = 50, \mathcal{E}\mathcal{W}(2, 2, 2)$	1.40686	1.90	2.27	2.36	2.59	4.44	3.04	0.67	2.22	1.67	2.84
$n = 100, \mathcal{E}\mathcal{W}(2, 2, 2)$	0.57517	1.60	2.17	2.25	2.81	4.34	3.77	0.86	2.22	1.67	2.84

2 Lista 4

2.1 Zadanie 1

Umieszczony poniżej kod zwraca p-value dla wykładniczych danych cenzurowanych I typu. Funkcja przyjmuje jako argumenty θ_0 , r , t_0 , s , n oraz *type*, gdzie:

- r to liczba danych kompletnych
- t_0 to czas, po którym zakończyliśmy eksperyment
- s to statystyka $\sum_{i=1}^r x_i$, gdzie x_i to dane kompletne
- n to liczba danych
- *type* podajemy w zależności od typu hipotezy:
 - "two.sided" - $\theta = \theta_0$ przeciwko $\theta \neq \theta_0$
 - "left" - $\theta \leq \theta_0$ przeciwko $\theta > \theta_0$
 - "right" - $\theta \geq \theta_0$ przeciwko $\theta < \theta_0$

Test oparty jest na ilorazie wiarygodności $\lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\theta, \mathbf{x})}{\sup_{\theta \in \Theta} L(\theta, \mathbf{x})}$. Korzystamy z faktu, że $-2\ln(\lambda(\mathbf{X}))$ ma rozkład $\chi^2(1)$. W naszym przypadku $L(\theta, \mathbf{x}) = \frac{n!}{(n-r)!} \theta^r e^{-\theta(s+t_0(n-r))}$ przyjmuje maximum dla $\theta = \frac{r}{s+t_0(n-r)}$.

```
pval = function(theta0, r ,t0 , s, n, type){
  if(r == 0){
    return(1)
  }
  s = s + t0*(n-r)
  lambda = (theta0*s/r)^r*exp(-theta0*s + r)
  K = 1 - pchisq(-2*log(lambda),1)
  if(type == "two.sided"){
    return(K)
  }
  if(type == "left"){
    if(theta0 > r/s){
      return(1)
    }
    else{
      return(K)
    }
  }
  if(type == "right"){
    if(theta0 < r/s){
      return(1)
    }
  }
}
```

```

else{
  return(K)
}
}
}

```

2.2 Zadanie 2

Poniższa funkcja szacuje za pomocą symulacji moc lub rozmiar testu $\theta = \theta_0$ przeciwko $\theta \neq \theta_0$ dla wykładniczych danych cenzurowanych I typu. Przyjmuje jako argumenty $\theta, \theta_0, t_0, n, nsim, \alpha$, przy konwencji z zadania 1, gdzie:

- $nsim$ to liczba symulacji
- α to poziom istotności testu
- θ jest parametrem rozkładu danych, które generujemy na potrzeby testu

```

sim = function(theta,theta0, t0, n, nsim, alpha){
  failed = 0
  for(i in 1:nsim){
    data = sort(rexp(n, theta))
    r = sum(data <= t0)
    s = sum(data[1:r])
    p = pval(theta0, r ,t0 , s, n, type = "two.sided")
    if(p < alpha){
      failed = failed + 1
    }
  }
  return(failed/nsim)
}

```

W tabelach 3 oraz 4 znajdziemy wyniki funkcji **sim** dla różnych θ przy $\theta_0 = 0.5, t_0 = 0.7, nsim = 1000, \alpha = 0.05$. Wartość $\theta = \theta_0 = 0.5$ jest oszacowaniem rozmiaru, natomiast pozostałe 10 wartości $\theta \neq \theta_0 = 0.5$ mocami testu. Zgodnie z przewidywaniami dla $\theta = \theta_0$ otrzymujemy rozmiar bliski poziomowi istotności $\alpha = 0.05$.

Tablica 3: Symulacyjnie wyznaczona istotność testu dla $n = 20$

θ	0.250	0.50	0.750	1.000	1.250	1.500	1.750	2.000	2.250	2.5	2.75
β_θ	0.323	0.06	0.199	0.528	0.759	0.914	0.973	0.992	0.996	1.0	1.00

Tablica 4: Symulacyjnie wyznaczona istotność testu dla $n = 50$

θ	0.250	0.50	0.750	1.000	1.250	1.500	1.75	2	2.25	2.5	2.75
β_θ	0.571	0.06	0.429	0.866	0.994	0.999	1.00	1	1.00	1.0	1.00

2.3 Zadanie 3

Przeprowadzamy, na podstawie danych z zadania 3 z listy 2, test hipotezy $\theta = 1$ przeciwko $\theta \neq 1$ na poziomie istotności $\alpha = 0.05$. W naszym przypadku:

- $t_0 = 1$
- $n = 20$
- $r = 10$
- $s_A = 4.2158262$
- $s_B = 3.4586688$

W Tabeli 5 widoczne są p-wartości dla poszczególnych zbiorów danych oraz rozstrzygnięcie testu. W przypadku obu zbiorów ich charakterystyka nie pozwala na odrzucenie hipotezy $\theta = 1$.

Tablica 5: Testy na zbiorach A i B

	A	B
p-value	0.24	0.32
rozstrzygnięcie	nieodrzucona	nieodrzucona