

Sprawozdanie 2

Marta Hałas i Igor Misterowicz

2025-11-08

Spis treści

1	Lista 5	2
1.1	Zadanie 1	2
1.1.1	Implementacja estymatora Kaplana-Meiera	2
1.1.2	Implementacja estymatora Fleminga-Harringtona	2
1.1.3	a) Wykres estymatora Kaplana-Meiera	3
1.1.4	b) Wykres estymatora Fleminga-Harringtona	3
1.2	Zadanie 2	4
1.2.1	Implementacja ogona	4
1.2.2	Implementacja estymatora Kaplana-Meiera z ogonem	5
1.2.3	Implementacja wykresu estymatora Kaplana-Meiera z ogonem	5
1.2.4	Wykresy estymatorów Kaplana-Meiera z ogonem dla zbiorów A i B	6
1.3	Zadanie 3	6
1.3.1	Implementacja funkcji kwantylowej uogólnionego rozkładu wykładniczego	6
1.3.2	Implementacja symulacji	7
1.3.3	Oszacowanie średniej ogólnionego rozkładu wykładniczego dla $\alpha = \lambda = 0.5$	7
1.3.4	Wyniki symulacji	7
2	Lista 7	9
2.1	Zadanie 1	9
2.2	Zadanie 2	10
3	Lista dodatkowa	10
3.1	Zadanie 1	10

1 Lista 5

1.1 Zadanie 1

1.1.1 Implementacja estymatora Kaplana-Meiera

Estymator jest postaci:

$$\widehat{S}(t) = \prod_{i: t_{(i)} \leq t} \left(1 - \frac{d_i}{r_i}\right)$$

, gdzie

$$r_i = \sum_{j=1}^n \mathbf{1}_{[t_i, \infty)}(t_j)$$

$$d_i = \sum_{j=1}^n \mathbf{1}_{\{t_{(i)}\}}(t_j) \mathbf{1}_{\{1\}}(\delta_i)$$

Jako argumenty przyjmujemy wektory czastów t_i oraz indykatorów kompletności δ_i .

```
km = function(t, delta){
  n = length(t)
  times = sort(unique(t))
  r = sapply(times, FUN = function(var) sum(t >= var))
  d = sapply(times, FUN = function(var) sum(t == var & delta == 1))
  conditionals = 1 - d/r
  S = function(x){
    S_x = prod(conditionals[times <= x])
    return(S_x)
  }
  return(S)
}
```

1.1.2 Implementacja estymatora Fleminga-Harringtona

Estymator jest postaci

$$\widehat{S}(t) = \exp\left(-\sum_{i: t_{(i)} \leq t} \frac{d_i}{r_i}\right)$$

, gdzie d_i , r_i oraz argumenty funkcji są takie jak dla estymatora Kaplana-Meiera.

```
fh = function(t, delta){
  n = length(t)
  times = sort(unique(t))
  r = sapply(times, FUN = function(var) sum(t >= var))
  d = sapply(times, FUN = function(var) sum(t == var & delta == 1))
  S = function(x){
    S_x = exp(-sum((d/r)[times <= x]))
    return(S_x)
  }
}
```


```

}
return(S)
}

```

1.1.3 a) Wykres estymatora Kaplana-Meiera

Na wykresie 1 znajdziemy funkcje przeżycia zwrócone przez estymator Kaplana-Meiera dla zbiorów danych A i B.




Rysunek 1: Funkcje przeżycia wyrażone estymatorem Kaplana-Meiera

1.1.4 b) Wykres estymatora Fleminga-Harringtona

Na wykresie 2 znajdziemy wykresy funkcji przeżycia zwróconych przez estymator Fleminga-Harringtona dla zbiorów danych A i B.

Funkcje przeżycia wyrażone estymatorem Fleminga–Harringtona



Rysunek 2: Funkcje przeżycia wyrażone estymatorem Fleminga-Harringtona

Użycie różnych estymatorów nie wpływa na wnioski dotyczące działania leków A i B. Zauważamy, że dla $t \leq 0.2$ częściej zdrowieją pacjenci, którzy przyjmują lek A, natomiast dla $0.4 \leq t \leq 0.9$ mamy więcej ozdrowień dla leku B. W tabeli 1, widzimy dokładne wartości obu estymatorów dla leku A.

Tablica 1: Porównanie wyników estymatora Kaplana-Meiera oraz Fleminga-Harringtona dla czasów do wyzrowień, przyjmując lek A

	S(0.033)	S(0.087)	S(0.088)	S(0.244)	S(0.278)	S(0.408)	S(0.588)	S(0.641)	S(0.907)	S(0.942)
Fleming-Harrington	0.950	0.900	0.850	0.800	0.750	0.700	0.650	0.60	0.550	0.500
Kaplan-Meier	0.951	0.902	0.854	0.805	0.756	0.707	0.659	0.61	0.561	0.512

1.2 Zadanie 2

1.2.1 Implementacja ogona

Implementowany ogon Browna, Hollanda i Kowara jest postaci

$$\widehat{S}(t) = \exp \left[\frac{\ln \widehat{S}(t^+)}{t^+} t \right]$$

, gdzie $t^+ = t_{(n)}$. Argumentami funkcji implementowanych w tym zadaniu są już wcześniej używane wektory obserwowanych czasów życia t_i oraz indykatorów kompletności δ_i .

```
km_bhk_tail = function(t, delta){
  n = length(t)
  S = km(t, delta)
  t_plus = t[n]
  S_tail = function(x){
    S_x = exp(log(S(t_plus))/t_plus*x)
    return(S_x)
  }
  return(S_tail)
}
```

1.2.2 Implementacja estymatora Kaplana-Meiera z ogonem


```
km_extended = function(t, delta){
  n = length(t)
  t_plus = t[n]
  base = km(t, delta)
  tail = km_bhk_tail(t,delta)
  S = function(x){
    if(x <= t_plus) return(base(x))
    if(x > t_plus) return(tail(x))
  }
  return(S)
}
```

1.2.3 Implementacja wykresu estymatora Kaplana-Meiera z ogonem

```
plot_km_extended= function(t, delta){
  S = km_extended(t, delta)
  x_ax = seq(from = 0, to = 5, by = 0.01)
  y_ax = sapply(x_ax, FUN = S)
  p = ggplot(data = NULL, aes(x = x_ax, y = y_ax)) +
    geom_line(colour = "Blue", linewidth = 1) +
    xlab("t") +
    ylab("S(t)")
  return(p)
}
```

1.2.4 Wykresy estymatorów Kaplana-Meiera z ogonem dla zbiorów A i B

Wykresy estymatorów Kaplana-Meiera z ogonem dla leków A i B



Rysunek 3: Wykresy estymatorów Kaplana-Meiera z ogonem dla leków A i B

Na wykresie 3 znajdują się funkcje przeżycia zwrócone przez estymator Kaplana-Mayera z ogonem dla czasów do wyzdrowień przy terapiach lekami A i B. Ponieważ oba zbiory danych mają takie same t^+ , ogony są identyczne.

1.3 Zadanie 3

1.3.1 Implementacja funkcji kwantylowej uogólnionego rozkładu wykładniczego

$$Q(x) = -\frac{1}{\lambda} \ln(1 - x^{1/\alpha})$$

```
Qexp_g = function(lambda, alpha){  
  f <- function(x){  
    return(-1/lambda*log((1-x^(1/alpha))))  
  }  
  return(f)  
}
```

1.3.2 Implementacja symulacji

Funkcja przyjmuje jako argumenty:

- t_0 - czas cenzurowania
- λ, α - parametry uogólnionego rozkładu wykładniczego
- n - wielkość próby
- t_{val} - czas w którym obliczamy wartość $\hat{S}$
- $nsim$ - liczba symulacji

```
sim = function(t0, lambda, alpha, n, t_val, nsim = 5000){
  result = numeric(nsim)
  for(i in 1:nsim){
    Q = Qexp_g(lambda, alpha)
    data = sort(Q(runif(n)))
    delta = (data <= t0)
    data[data > t0] = t0
    result[i] = km_extended(data, delta)(t_val)
  }
  return(result)
}
```

1.3.3 Oszacowanie średniej ogólnionego rozkładu wykładniczego dla $\alpha = \lambda = 0.5$


```
Q = Qexp_g(0.5, 0.5)
round(mean(Q(runif(100000)))), 2)
```

```
## [1] 1.22
```

1.3.4 Wyniki symulacji

Używamy domyślnej liczby symulacji 5000. Na wykresie 4 widoczne są histogramy wartości estymatora Kaplana-Meiera z ogonem w punktach t_0 oraz $2t_0$, dla parametrów uogólnionego rozkładu wykładniczego $\alpha = \lambda = 0.5$ oraz $t_0 = 1.22$. Zauważamy, że wraz ze wzrostem n , otrzymany rozkład staje się coraz bardziej symetryczny, ponadto obserwujemy szybko zanikające ogony. Te obserwacje są charakterystyczne dla rozkładu normalnego. Z drugiej strony widzimy nietypowy, odstający słupek dla $n = 100$, $S(t_0)$. Możemy podejrzewać, że estymator Kaplana-Meiera z ogonem jest asymptotycznie normalny w punkcie $2t_0$, ale dla t_0 trudno o rozstrzygnięcie.

Histogramy oszacowań funkcji przeżycia, $\alpha = \lambda = 0.5$, $t_0 = 1.22$



Rysunek 4: Histogramy oszacowań funkcji przeżycia dla uogólnionego rozkładu wykładniczego, $\alpha = \lambda = 0.5$, $t_0 = 1.22$

2 Lista 7

2.1 Zadanie 1

Używamy notacji z 1 zadania z listy 5. Funkcja przyjmuje jako argumenty: wektory t , δ , wartości τ , α oraz $tail$ gdzie:

- τ - wartość maksymalnego, znanego apriori, czasu życia
- α - oznacza poziom istotności
- $tail$ - wartość logiczna, wskazuje czy używamy estymatora z ogonem

Zwracane realizacje przedziałów ufności są postaci:

$$T_L = \hat{\mu}_\tau - z(1 - \alpha/2)\sqrt{\hat{V}(\hat{\mu}_\tau)}$$

$$T_U = \hat{\mu}_\tau + z(1 - \alpha/2)\sqrt{\hat{V}(\hat{\mu}_\tau)}$$

$$\hat{V}(\hat{\mu}_\tau) = \sum_{i=1}^D \hat{\mu}_\tau^2 \frac{d_i}{r_i(r_i - d_i)}$$

$$\hat{\mu}_\tau = \int_{s_i}^{\tau} \hat{S}(t) dt$$

, gdzie:

- z - funkcja kwantylową rozkładu $\mathcal{N}(0,1)$
- D - liczba nieocenzurowanych czasów życia
- s_i - uporządkowane dane nieocenzurowane

```
est_int = function(t, delta, tau, alpha, tail = FALSE){
  if(tail == FALSE){
    S = Vectorize(km(t, delta))
  }
  else{
    S = Vectorize(km_extended(t, delta))
  }

  mu = integrate(S, 0, tau, subdivisions = 10000)$value

  times = sort(unique(t))
  r = sapply(times, FUN = function(var) sum(t >= var))
  d = sapply(times, FUN = function(var) sum(t == var & delta == 1))

  s = t[delta == 1]
  event_times = sort(unique(s))
  D = length(event_times)
  event_idx = match(event_times, times)

  V = 0
  for(i in 1:D){
    j = event_idx[i]
```

```

    integral = integrate(S, event_times[i], tau, subdivisions = 10000)$value
    V = V + integral^2 * d[j]/(r[j]*(r[j] - d[j]))
  }

  lower = mu - qnorm(1 - alpha/2) * sqrt(V)
  upper = mu + qnorm(1 - alpha/2) * sqrt(V)

  result = c(round(lower, 2), round(upper, 2))

  return(result)
}

```

2.2 Zadanie 2

W tabeli 2, znajdują się realizacje przedziałów ufności dla średniego czasu do progresju raka jajnika, na poziomie ufności 0.95. Użyty został estymator bez ogona. Ze względu na podobne wartości maksymalne 1206 oraz 1119, wartości τ równe 1250 oraz 1500 możemy uznać za rozsądne dla obu zbiorów danych. Przy niskim stopniu zaawansowania choroby mamy dużo szersze realizacje przedziałów. Zauważamy, że wybór odpowiedniego τ jest kluczowy, ponieważ dobranie złej wartości może skutować znaczącym błędem. Jak należałoby się spodziewać, granice realizacji przedziałów są znacznie wyższe w przypadku pacjentów z niskim stopniem zaawansowania choroby.

Tablica 2: Realizacje przedziałów ufności dla czasów do progresji raka jajnika

	$\tau = 1500$	$\tau = 1250$
Niski stopień zaawansowania	[589.92, 1285.57]	[520.06, 1077.61]
Wysoki stopień zaawansowania	[232.74, 593.68]	[246.73, 535.92]

3 Lista dodatkowa

3.1 Zadanie 1

Korzystam z wcześniej zaimplementowanych funkcji związanych z uogólnionym rozkładem wykładniczym. Są to funkcja kwantylowa, dystrybuanta oraz generator danych cenzurowanych losowo.

```

kwantylowa<- function(u,a,l) {
  (-1/l)*log(1-u^(1/a))
}

losowo<-function(T1,n,a,l){
  u<-runif(n)
  wartosc<-kwantylowa(u,a,l)
  cenzurowane<-runif(n,min=0,max=T1)
  pary<-pmin(wartosc,cenzurowane)
  indykator <- as.integer(wartosc<=cenzurowane)
  data.frame("czas obserwowania" = pary, indykator = indykator)
}

dystrybuanta <- function(x, a, lambda) {

```

```

    ifelse(x < 0, 0, (1 - exp(-lambda * x))^a)
}

```

Funkcja `s_int()` oblicza realizacje asymptotycznych punktowych przedziałów ufności dla estymatora Kaplana-Meiera w punkcie t_0 . Ponadto przyjmuje wektory danych t_i , indyktorów kompletności δ_i oraz poziom istotności α . Zwracane są realizacje trzech różnych wariantów przedziałów: liniowy, po transformacjach $\ln(x)$ oraz $\ln(\frac{x}{1-x})$. Przedziały są postaci:

dla $f(x) = x$:

$$\hat{S}_n(t_0) \pm z(1 - \alpha/2)\sqrt{\hat{\sigma}_n}$$

dla $f(x) = \ln(x)$:

$$\hat{S}_n(t_0)^{\exp(\pm z(1 - \alpha/2)\sqrt{\hat{\sigma}_n}/|\ln(\hat{S}_n(t_0))|)}$$

dla $f(x) = \ln(\frac{x}{1-x})$:

$$\frac{\hat{S}_n(t_0)}{\hat{S}_n(t_0) + (1 - \hat{S}_n(t_0)) \exp(\pm z(1 - \alpha/2) \frac{\sqrt{\hat{\sigma}_n}}{1 - \hat{S}_n(t_0)})}$$

, gdzie

$$\hat{\sigma}_n = \hat{S}_n^2(t_0) \sum_{i:t_i \leq t_0} \frac{d_i}{r_i(r_i - d_i)}$$

```

s_int = function(t, delta, t0, alpha){
  S = km(t,delta)

  times = sort(unique(t))
  r = sapply(times, FUN = function(var) sum(t >= var))
  d = sapply(times, FUN = function(var) sum(t == var & delta == 1))

  v = sum((d/(r*(r - d)))[times <= t0])

  sigma = S(t0)^2*v

  lower_plain = S(t0) - qnorm(1 - alpha/2) * sqrt(sigma)
  upper_plain = S(t0) + qnorm(1 - alpha/2) * sqrt(sigma)

  lower_log = S(t0)^exp(qnorm(1 - alpha/2)*sqrt(v)/abs(log(S(t0))))
  upper_log = S(t0)^exp(-qnorm(1 - alpha/2)*sqrt(v)/abs(log(S(t0))))

  lower_logit = S(t0)/(S(t0) + (1 - S(t0))*exp(qnorm(1 - alpha/2)*sqrt(v)/((1-S(t0)))))
  upper_logit = S(t0)/(S(t0) + (1 - S(t0))*exp(-qnorm(1 - alpha/2)*sqrt(v)/((1-S(t0)))))

  plain_result = c(round(lower_plain, 2),round(upper_plain,2))
  log_result = c(round(lower_log, 2),round(upper_log,2))
  logit_result = c(round(lower_logit, 2),round(upper_logit,2))

  lst = list(plain = plain_result,
             log = log_result,

```

```

        logit = logit_result)

    return(lst)
}

```

Funkcja `int_sim()` przyjmuje dodatkowo argumenty `n_data`, który oznacza liczbę danych, oraz `n_sim`, który określa liczbę powtórzeń w symulacji. Dla realizacji przedziałów ufności z funkcji `s_int()` zwracane są symulacyjnie wyznaczone prawdopodobieństwa pokrycia oraz średnie długości przedziałów. Dane generowane są z rozkładu $\mathcal{GE}(0.5, 0.5)$.

```

int_sim = function(t0, alpha, n_data, n_sim = 5000){
  plain_count = 0
  plain_len = 0
  log_count = 0
  log_len = 0
  logit_count = 0
  logit_len = 0

  for(i in 1:n_sim){
    data = losowo(2, n_data, 0.5, 0.5)

    t = data$czas.obserwowania
    delta = data$indykator

    if(all(delta == 1)) print("all_1")
    if(all(delta == 0)) print("all_0")

    interval = s_int(t, delta, t0, alpha)$plain

    lower = interval[1]
    upper = interval[2]

    S = 1 - dystrybuanta(t0, 0.5, 0.5)
    plain_len = plain_len + (upper - lower)
    if(lower <= S & upper >= S) {
      plain_count = plain_count + 1
    }

    interval = s_int(t, delta, t0, alpha)$log

    lower = interval[1]
    upper = interval[2]

    log_len = log_len + (upper - lower)
    if(lower <= S & upper >= S) {
      log_count = log_count + 1
    }

    interval = s_int(t, delta, t0, alpha)$logit

    lower = interval[1]
    upper = interval[2]
  }
}

```

```

logit_len = logit_len + (upper - lower)
if(lower <= S & upper >= S) {
  logit_count = logit_count + 1
}
}

lst = list(plain = round(c(plain_count/n_sim, plain_len/n_sim),3),
          log = round(c(log_count/n_sim, log_len/n_sim),3),
          logit = round(c(logit_count/n_sim, logit_len/n_sim),3))

return(lst)
}

```

W tabelach 3 - 8 umieszczone zostały symulacyjnie wyznaczone pokrycia oraz średnie długości realizacji asymptotycznych punktowych przedziałów ufności dla estymatora Kaplana-Meiera. Użyty został poziom istotności $\alpha = 0.05$ oraz liczba symulacji $n_{sim} = 5000$. Korzystam z konwencji w której przekształcenie $f(x) = x$ nazywamy plain, $f(x) = \ln(x)$ log, a $f(x) = \ln(\frac{x}{1-x})$ logit. Zgodnie z intuicją, wraz ze wzrostem n , długości realizacji przedziałów stają się krótsze. Najgorzej wypada nam przedział ufności liniowy “plain”, ponieważ często otrzymujemy pokrycie niższe niż spodziewane 0.95. Nie obserwujemy przy tym wyraźnego skrócenia średniej długości przedziału.

Tablica 3: Symulacyjnie wyznaczone pokrycia i długości punktowych przedziałów ufności estymatora Kaplana-Meiera dla $S(0.2)$ i $n = 30$

	plain	log	logit
pokrycie	0.932	0.953	0.964
długość	0.330	0.332	0.322

Tablica 4: Symulacyjnie wyznaczone pokrycia i długości punktowych przedziałów ufności estymatora Kaplana-Meiera dla $S(0.2)$ i $n = 50$

	plain	log	logit
pokrycie	0.931	0.946	0.950
długość	0.258	0.258	0.254

Tablica 5: Symulacyjnie wyznaczone pokrycia i długości punktowych przedziałów ufności estymatora Kaplana-Meiera dla $S(0.2)$ i $n = 100$

	plain	log	logit
pokrycie	0.948	0.948	0.953
długość	0.184	0.184	0.182

Tablica 6: Symulacyjnie wyznaczone pokrycia i długości punktowych przedziałów ufności estymatora Kaplana-Meiera dla $S(0.7)$ i $n = 30$

	plain	log	logit
pokrycie	0.925	0.946	0.952
długość	0.384	0.370	0.367

Tablica 7: Symulacyjnie wyznaczone pokrycia i długości punktowych przedziałów ufności estymatora Kaplana-Meiera dla $S(0.7)$ i $n = 50$

	plain	log	logit
pokrycie	0.932	0.945	0.950
długość	0.299	0.293	0.291

Tablica 8: Symulacyjnie wyznaczone pokrycia i długości punktowych przedziałów ufności estymatora Kaplana-Meiera dla $S(0.7)$ i $n = 100$

	plain	log	logit
pokrycie	0.946	0.952	0.952
długość	0.213	0.211	0.210