

Sprawozdanie 2

Igor Misterowicz

2025-11-08

Spis treści

1	Zadanie 3. Dopasowanie modeli autoregresji do szeregu gtemp_both	2
1.1	Cel zadania	2
1.2	a) Stacjonarność danych	2
1.2.1	Sprawdzenie stacjonarności	2
1.2.2	Transformacja różnicowania	3
1.2.3	Trend wielomianowy	4
1.3	b) Wybór optymalnych rzędów modeli autoregresji AR(p)	4
1.4	c) Dopasowanie modelu AR(p)	6
1.5	d) Asymptotyczne przedziały ufności oraz testy istotności dla parametrów modelu AR(p) . .	8
1.5.1	Wyznaczenie asymptotycznych przedziałów ufności	8
1.5.2	Testy istotności współczynników modelu	9
1.6	e) Testy dopasowania modelu	10
1.7	f) Predykcje	14
1.8	h) Porównanie podejść do modelowania	18

1 Zadanie 3. Dopasowanie modeli autoregresji do szeregu gtemp_both

1.1 Cel zadania

Celem niniejszego zadania jest wykonanie pełnej analizy dotyczącej estymacji oraz diagnostyki modeli autoregresyjnych AR(p), w tym oceny jakości i poprawności ich dopasowania do danych. W ramach pracy rozpatrywane są zagadnienia wyszczególnione w spisie treści.

W analizie wykorzystujemy zbiór danych gtemp_both, który zawiera informacje o temperaturze globalnej (obejmującej obszary lądowe i oceaniczne) w latach 1850–2023. Wartości te zostały obliczone jako odchylenia od średniej temperatury globalnej wyznaczonej dla okresu referencyjnego 1991–2020.


```
data = gtemp_both
```

```
head(data)
```

```
## Time Series:  
## Start = 1850  
## End = 1855  
## Frequency = 1  
## [1] -0.24 -0.25 -0.27 -0.15 -0.05 -0.16
```

1.2 a) Stacjonarność danych


1.2.1 Sprawdzenie stacjonarności



Rysunek 1: Wykres szeregu gtemp.both

Parząc na wykres 1 widzimy, że dane nie są szeregiem stacjonarnym. Spodziewamy się, że potrzebna będzie eliminacja trendu kwadratowego. Gołym okiem nie widzimy sezonowości.


Funkcja autokorelacji szeregu gtemp_both



Rysunek 2: Funkcja autokorelacji szeregu gtemp.both

Na wykresie 2 widzimy, że szereg gtemp_both ma wysokie wartości funkcji autokorelacji. Potwierdza to nasze przypuszczenia o niestacjonarności danych.


1.2.2 Transformacja różnicowania



Rysunek 3: Wyniki różnicowania szeregu na danych gtemp.both

Jak widzimy na wykresie 3 jednokrotne zróżnicowanie naszych danych wyeliminowało większość korelacji występującej między danymi. Tej transformacji będziemy używać w dalszej części analizy, ponieważ dwukrotne zróżnicowanie nie poprawiło uzyskanych rezultatów.

1.2.3 Trend wielomianowy




Rysunek 4: Wyniki eliminacji trendu wielomianowego na danych gtemp.both

Jak widzimy na wykresie 4, trend liniowy słabo opisuje nasze dane. Dużo lepiej sprawdził się trend kwadratowy, dlatego w dalszych etapach nie będziemy rozważać wariantu liniowego.

1.3 b) Wybór optymalnych rzędów modeli autoregresji AR(p)


Dobieramy współczynnik p dla modelu z trendem kwadratowym. Na wykresie 5 widzimy, że PACF zanika dla opóźnień większych od 1. Dla tej wartości mamy również najniższe AIC oraz FPE, dlatego ustalamy

$p = 1$.



Rysunek 5: Wskaźniki na dobór odpowiedniego rzędu modelu AR dla danych gtemp.both bez trendu kwadratowego

W przypadku danych po różnicowaniu, wskaźniki widoczne na wykresie 6 nie wskazują już jednoznacznie optymalnej liczby parametrów. PACF zanika dla opóźnień większych od 5, dla tej wartości mamy również najniższe AIC. Z drugiej strony FPE wskazuje że optymalny będzie rząd równy jeden. Mamy dwa głosy do jednego za $p = 5$ i ten rząd modelu przyjmiemy w dalszych częściach analizy.



Rysunek 6: Wskaźniki na dobór odpowiedniego rzędu modelu AR dla danych gtemp.both po zróżnicowaniu

1.4 c) Dopasowanie modelu AR(p)

Wobec wybranych wcześniej p , nasz model na danych po eliminacji trendu kwadratowego jest postaci:

$$X_n = \phi_1 X_{n-1} + \varepsilon,$$

a po różnicowaniu:

$$X_n = \psi_1 X_{n-1} + \dots + \psi_5 X_{n-5} + \varepsilon,$$

gdzie $\phi_i, \psi_i \in \mathbb{R}$, a ε jest resztą.

Dopasowujemy współczynniki dla modelu AR(1) po eliminacji trendu kwadratowego:

```
quad_model_yw = ar(data - trend.kwadrat,
                    method = "yule-walker",
                    order.max = 1,
                    aic = F)

quad_model_mle = ar(data - trend.kwadrat,
                    method = "mle",
                    order.max = 1,
                    aic = F)
```

Tablica 1: Współczynnik ϕ_1 modelu AR(1) dla danych gtemp_both po eliminacji trendu kwadratowego

	ϕ_1
yule-walker	0.301
mle	0.305

Dopasowujemy współczynniki do modelu AR(5) po transformacji różnicowania:

```
dif_model_yw = ar(diff(data),
                  method = "yule-walker",
                  order.max = 5,
                  aic = F)

dif_model_mle = ar(diff(data),
                  method = "mle",
                  order.max = 5,
                  aic = F)
```

Tablica 2: Współczynniki ψ_i modelu AR(5) dla danych gtemp_both po różnicowaniu

	ψ_1	ψ_2	ψ_3	ψ_4	ψ_5
Yule-walker	-0.627	-0.463	-0.392	-0.278	-0.168
Mle	-0.631	-0.470	-0.394	-0.281	-0.172

W tabelach 1 oraz 2 widzimy współczynniki ϕ_1 oraz ψ_i z naszych modeli dopasowanych za pomocą metod Yula-Walkera oraz największej wiarygodności (MLE). Obie metody zwracają podobny wynik i spodziewamy się, że ich wybór nie będzie miał znaczenia dla dalszej części zadania.

1.5 d) Asymptotyczne przedziały ufności oraz testy istotności dla parametrów modelu AR(p)

1.5.1 Wyznaczenie asymptotycznych przedziałów ufności

Korzystamy z twierdzenia o asymptotycznej normalności:

$$\hat{\phi}_i \approx \mathcal{N}(\phi_i, \frac{\sigma_i^2}{n}),$$

stąd przedział ufności na poziomie α jest postaci:

$$\hat{\phi}_i \pm z_{1-\alpha/2} \frac{\sigma_i}{\sqrt{n}},$$

gdzie z jest funkcją kwantylową rozkładu normalnego.

Korzystamy z faktu że dostępne w modelu *asy.var.coef* to nasze $\frac{\sigma_i^2}{n}$. Ustalamy $\alpha = 0.05$.

Obliczamy przedziały ufności dla współczynnika ϕ_1 w modelu z trendem kwadratowym:

```
alpha = 0.05
quad_var_yw = quad_model_yw$asy.var.coef
quad_var_mle = quad_model_mle$asy.var.coef

quad_range_yw = qnorm(1-alpha/2)*sqrt(quad_var_yw)
quad_range_mle = qnorm(1-alpha/2)*sqrt(quad_var_mle)

quad_int_yw = paste0("[",
  signif(quad_model_yw$ar-quad_range_yw,3),
  ", ",
  signif(quad_model_yw$ar+quad_range_yw,3),
  "]"")

quad_int_mle = paste0("[",
  signif(quad_model_mle$ar-quad_range_mle,3),
  ", ",
  signif(quad_model_mle$ar+quad_range_mle,3),
  "]"")
```

Tablica 3: Przedziały ufności dla współczynnika ϕ_1 dla modelu AR(1) na danych gtemp.both po redukcji trendu kwadratowego

	ϕ_1
yule-walker	[0.159, 0.444]
MLE	[0.164, 0.447]

Obliczam przedziały ufności dla współczynników ψ_i modelu na zróżnicowanych danych.

```
alpha = 0.05
dif_var_yw = diag(dif_model_yw$asy.var.coef)
dif_var_mle = diag(dif_model_mle$asy.var.coef)
```



```

dif_range_yw = qnorm(1-alpha/2)*sqrt(dif_var_yw)
dif_range_mle = qnorm(1-alpha/2)*sqrt(dif_var_mle)

dif_int_yw = paste0("[",
                    signif(dif_model_yw$ar-dif_range_yw,3),
                    ", ",
                    signif(dif_model_yw$ar+dif_range_yw,3),
                    "]")

dif_int_mle = paste0("[",
                    signif(dif_model_mle$ar-dif_range_mle,3),
                    ", ",
                    signif(dif_model_mle$ar+dif_range_mle,3),
                    "]")

```

Tablica 4: Przedziały ufności dla współczynników ψ_i dla modelu AR(5) na różnicowanych danych gtemp.both

	ψ_1	ψ_2	ψ_3	ψ_4	ψ_5
yule-walker	[-0.776, -0.477]	[-0.635, -0.29]	[-0.568, -0.216]	[-0.45, -0.106]	[-0.317, -0.0183]
MLE	[-0.778, -0.485]	[-0.638, -0.301]	[-0.566, -0.222]	[-0.45, -0.113]	[-0.318, -0.0255]

Nasze realizacje przedziałów znajdziemy w tabelach 3 oraz 4. Nie obserwujemy znaczących różnic spowodowanych metodą dopasowania modelu.

1.5.2 Testy istotności współczynników modelu

Używany przez nas wskaźnik istotności jest postaci:

$$ratio = \frac{\psi_i}{1,96se(\psi_i)}.$$

Jeżeli $|ratio| < 1$ współczynnik uznajemy za statystycznie nieistotny. Obliczam współczynniki istotności dla modelu dopasowanego na danych po eliminacji trendu kwadratowego:

```

quad_ratio_yw = quad_model_yw$ar/(1.96*sqrt(quad_var_yw))
quad_ratio_mle = quad_model_mle$ar/(1.96*sqrt(quad_var_mle))

```

Tablica 5: Wskaźnik istotności współczynnika ϕ_1 modelu AR(1) na danych gtemp.both po eliminacji trendu kwadratowego

	ϕ_1
Yule-Walker	2.11
MLE	2.16

Obliczam współczynniki istotności dla modelu dopasowanego na danych po zroźnicowaniu:

```
dif_ratio_yw = dif_model_yw$ar/(1.96*sqrt(dif_var_yw))
dif_ratio_mle = dif_model_mle$ar/(1.96*sqrt(dif_var_mle))
```

Tablica 6: Wskaźnik istotności współczynników ψ_i modelu AR(5) na danych gtemp.both po zróżnicowaniu

	ψ_1	ψ_2	ψ_3	ψ_4	ψ_5
Yule-Walker	-4.19	-2.69	-2.23	-1.62	-1.12
MLE	-4.31	-2.79	-2.28	-1.67	-1.17

Wskaźniki istotności znajdziemy w tabelach 5 oraz 6. Wszystkie mają moduł większy od 1, czyli uznajemy je za statystycznie istotne.


1.6 e) Testy dopasowania modelu

Funkcja autokorelacji na resztach z modelu z trendem kwadratowym:


```
par(mfrow = c(2,1))

acf(na.omit(quad_model_yw$resid),
    main = "ACF, dopasowanie metodą Yula-Walkera",
    xlab = "Opóźnienie")
acf(na.omit(quad_model_mle$resid),
    main = "ACF, dopasowanie metodą MLE",
    xlab = "Opóźnienie")
```

ACF, dopasowanie metoda Yula-Walkera



ACF, dopasowanie metoda MLE




Rysunek 7: ACF na resztach z modelu AR(1) dopasowanego na danych gtemp.both po eliminacji trendu kwadratowego

Funkcja autokorelacji na resztach z modelu z różnicowaniem:


```
par(mfrow = c(2,1))

acf(na.omit(dif_model_yw$resid),
    main = "ACF, dopasowanie metodą Yula-Walkera",
    xlab = "Opóźnienie")
acf(na.omit(dif_model_mle$resid),
    main = "ACF, dopasowanie metodą MLE",
    xlab = "Opóźnienie")
```

ACF, dopasowanie metoda Yula-Walkera



ACF, dopasowanie metoda MLE



Rysunek 8: ACF na resztach z modelu AR(1) dopasowanego na danych gtemp.both po różnicowaniu

Formalne testy Ljunga-Boxa białoszumowości dla reszt z modelu z trendem kwadratowym:

```
p1 = Box.test(na.omit(quad_model_yw$resid),
              type = "Ljung-Box")$p.value
p2 = Box.test(na.omit(quad_model_mle$resid),
              type = "Ljung-Box")$p.value
```

Tablica 7: P-wartość testu Ljunga-Boxa na resztach z modelu AR(1) na danych gtemp.both z trendem kwadratowym

	Yule.Walker	MLE
p-wartość	0.664	0.622

Formalne testy Ljunga-Boxa białoszumowości dla reszt z modelu z różnicowaniem:

```
p1 = Box.test(na.omit(dif_model_yw$resid),
              type = "Ljung-Box")$p.value
p2 = Box.test(na.omit(dif_model_mle$resid),
              type = "Ljung-Box")$p.value
```

Tablica 8: P-wartość testu Ljunga-Boxa na resztach z modelu AR(5) na danych gtemp.both po różnicowaniu

	Yule.Walker	MLE
p-wartość	0.847	0.892

Na wykresach 7 i 8 oraz w tabelach 7 i 8 znajdziemy wyniki testów białoszumowości na resztach z modelu AR(1). Mamy niskie wartości funkcji autokorelacji i nie odrzucamy hipotezy o białoszumowości reszt. Wnioskujemy, że wszystkie modele są dobrze dopasowane.

1.7 f) Predykcje

Na wykresie 9 znajdziemy, wyznaczone za pomocą modelu z eliminacją trendu kwadratowego, prognozy na przyszłe wartości odchylenia od średniej temperatury dla kolejnych 50 lat. Zauważamy, że prognoza jest naturalnym przedłużeniem dostrzeganego gołym okiem kwadratowego trendu wzrostowego i wróży szybkie ocieplenie klimatu.

Wykres 10 przedstawia prognozy oparte na modelu z użyciem różnicowania. Tym razem przewidywana zmiana temperatury przebiega łagodniej, w sposób liniowy. Nie jest ona naturalnym przedłużeniem widocznego trendu wzrostowego.

W obu przypadkach modele prognozują nieznaczny spadek temperatury w 2024 roku oraz zapowiadają wzrosty w kolejnych latach.

Wybór metody dopasowania Yulea-Walkera czy MLE nie miał istotnego znaczenia dla otrzymanych prognoz.

```
par(mfrow = c(2,1))

ahead = 50
pred = predict(quad_model_yw, n.ahead = ahead)
```

```

trend = predict.lm(quad_reg, newdata = data.frame(trend = 175:(175+ahead -1)))

forecast = pred$pred + trend

ts.plot(gtemp_both,
        forecast,
        lty = c(1,2),
        col = c("black","red"),
        main = "Metoda dopasowania Yulea-Walkera",
        xlab = "Rok")

pred = predict(quad_model_mle, n.ahead = ahead)


trend = predict.lm(quad_reg, newdata = data.frame(trend = 175:(175+ahead -1)))

forecast = pred$pred + trend


ts.plot(gtemp_both, forecast,
        lty = c(1,2),
        col = c("black","red","blue","blue"),
        main = "Metoda dopasowania MLE",
        xlab = "Rok")

```

Metoda dopasowania Yulea–Walkera



Metoda dopasowania MLE



Rysunek 9: Predykcje za pomocą modeli AR(1) na danych gtemp.both z trendem kwadratowym

```
par(mfrow = c(2,1))

ahead = 50

pred = predict(dif_model_yw, n.ahead = ahead)

last = gtemp_both[length(gtemp_both)]

forecast = diffinv(pred$pred, xi = last)

ts.plot(
  gtemp_both,
  forecast,
  lty = c(1, 2),
```



```

    col = c("black", "red"),
    main = "Metoda dopasowania Yulea-Walkera",
    xlab = "rok"
)

pred = predict(dif_model_mle, n.ahead = ahead)


last = gtemp_both[length(gtemp_both)]

forecast = diffinv(pred$pred, xi = last)


ts.plot(
  gtemp_both,
  forecast,
  lty = c(1, 2),
  col = c("black", "red"),
  main = "Metoda dopasowania MLE",
  xlab = "rok"
)

```

Metoda dopasowania Yulea–Walkera



Metoda dopasowania MLE



Rysunek 10: Predykcje za pomocą modeli AR(5) na zróżnicowanych danych gtemp.both

1.8 h) Porównanie podejść do modelowania

Metoda eliminacji trendu kwadratowego dała wizualnie bardzo przekonujący model. Jest ona bardziej ryzykownym podejściem, ponieważ obecny na oryginalnym wykresie trend kwadratowy może być przypadkowo wygenerowany przez błędzenie losowe. Niewątpliwą zaletą tego podejścia jest prosta postać modelu ($p = 1$, deterministyczny trend).

W obliczu niepewności czy założenie o obecności deterministycznego trendu jest realistyczne, lepszym podejściem będzie model z wykorzystaniem różnicowania. Prognozy, które otrzymaliśmy za jego pomocą zapowiadają liniowe ocieplenie klimatu, wolniejsze niż w przypadku trendu kwadratowego.

Zastosowanie metod dopasowania modelu (MLE lub Yulea-Walkera) nie wpłynęło na interpretację wyników.